

Introduzione all'apprendimento automatico

Mattia Masina

CdL in Informatica – Università di Bologna

Anno Accademico 2026/2027

Indice

1	Introduzione al Machine Learning e Alberi di Decisione	3
1.1	Fondamenti e Formulazione come Ottimizzazione	3
1.2	Tassonomia dei Compiti e Rappresentazione dei Dati	4
1.3	Alberi di Decisione ed Espressività	5
1.4	Costruzione Top-Down, Entropia e Information Gain	6
1.5	Attributi Continui e Gestione delle Soglie	7
1.6	Overfitting, Compromesso Bias-Varianza e Tecniche di Potatura	8
1.7	Criteri Alternativi di Impurità ed Ensemble Learning	9
1.8	Il Paradigma Probabilistico e Fondamenti Assiomatici	10
1.9	Probabilità Condizionata, Regola della Catena e Indipendenza Stocastica	11

1 Introduzione al Machine Learning e Alberi di Decisione

1.1 Fondamenti e Formulazione come Ottimizzazione

L'informatica tradizionale affronta la risoluzione dei problemi tramite la scrittura esplicita di algoritmi: un programmatore formalizza le regole logico-matematiche necessarie per trasformare i dati in ingresso nell'output desiderato. Tuttavia, per un'ampia classe di problemi complessi del mondo reale, definire regole deterministiche a priori risulta pressoché impossibile. Rientrano in questo ambito compiti percettivi e decisionali quali la **classificazione** (filtri anti-spam, analisi del sentiment, rilevamento di frodi finanziarie), la **visione artificiale** (riconoscimento di immagini e volti), l'elaborazione del linguaggio naturale e del segnale (riconoscimento vocale e musicale), l'**anomaly detection**, il **clustering** e l'**Intelligenza Artificiale Generativa**.

I domini trattati tramite Machine Learning condividono caratteristiche peculiari:

- **Bassa conoscenza meta-teorica:** non si dispone di una teoria formale chiusa in grado di descrivere analiticamente il fenomeno indagato.
- **Elevato numero di feature d'ingresso:** le istanze sono descritte da vettori ad altissima dimensionalità.
- **Grandi volumi di dati:** i modelli necessitano di moli imponenti di esempi storici per addestrarsi (ad esempio il dataset ImageNet, composto da oltre 10 milioni di immagini).
- **Adattabilità:** capacità intrinseca del modello di evolvere e ricalibrarsi all'arrivo di nuove distribuzioni di dati.

Il Paradigma del Machine Learning come Processo di Ottimizzazione

Formalmente, l'approccio di apprendimento automatico si articola in tre passaggi sequenziali:

1. **Scelta della classe di modelli:** si fissa una famiglia di funzioni parametrizzate dipendenti da un vettore di parametri θ (ad esempio una retta affine sul piano $y = ax + b$, con parametri a e b).
2. **Definizione della metrica di errore (*loss function*):** si stabilisce una funzione di costo oggettiva per valutare la discrepanza tra le predizioni e i valori reali (es. l'errore quadratico medio, *Mean Squared Error*).
3. **Addestramento (*training*):** si ottimizzano i parametri al fine di minimizzare l'errore cumulativo sull'insieme dei dati osservati.

Nonostante si tratti rigorosamente di una procedura di ottimizzazione matematica, si parla propriamente di *learning* per due ragioni fondamentali:

1. La calibrazione dei parametri si fonda sull'evidenza empirica: il sistema impara e trae pattern dall'esperienza pregressa memorizzata nel training set.
2. Nella maggior parte dei casi non esiste una soluzione analitica in forma chiusa per la minimizzazione dell'errore. Si ricorre quindi a metodi numerici iterativi (come la discesa

del gradiente) che raffinano progressivamente l'approssimazione simulando un percorso di apprendimento.

L'obiettivo primario di un modello addestrato è formulare **predizioni su nuovi dati** non inclusi nel training set (generalizzazione), collocando nuovi input nella corretta classe discreta o stimandone il valore continuo atteso. I modelli possono inoltre essere impiegati per estrarre conoscenza intrinseca dalla struttura dei dati, identificando raggruppamenti naturali (*cluster*) o correlazioni latenti.

1.2 Tassonomia dei Compiti e Rappresentazione dei Dati

I compiti di apprendimento si dividono in tre paradigmi principali in base alla natura dei dati disponibili:

- **Apprendimento Supervisionato (*Supervised Learning*)**: il dataset fornisce coppie input-output $\langle \mathbf{x}, y \rangle$. Se l'output y assume valori discreti si ha un problema di **classificazione**; se assume valori continui si ha un problema di **regressione**.
- **Apprendimento Non Supervisionato (*Unsupervised Learning*)**: il sistema riceve esclusivamente gli input $\mathbf{x}$, senza alcuna etichetta. Lo scopo è apprendere la distribuzione o la struttura interna dei dati tramite compiti di *clustering*, analisi delle componenti o *autoencoding*.
- **Apprendimento per Rinforzo (*Reinforcement Learning*)**: un agente interagisce attivamente con un ambiente, compiendo azioni e ricevendo ricompense scalari (*rewards*). Il modello apprende una politica decisionale volta a massimizzare il guadagno atteso a lungo termine (*model-free planning*).

Per definire i modelli si impiegano molteplici formalismi (alberi di decisione, modelli lineari, reti neurali artificiali) e svariate funzioni di perdita (Mean Squared Error, logistic loss, cross-entropy, distanza coseno, massimo margine).

Dalle Feature Ingegnerizzate al Deep Learning

Si definisce **feature** qualsiasi proprietà o misurazione numerica relativa a un dato utile a descriverne gli aspetti salienti (es. sintomi ed esami in ambito medico, dati anagrafici e interessi per la profilazione utente, temperatura e pressione per le previsioni meteorologiche). L'apprendimento è estremamente sensibile alla qualità delle feature fornite in ingresso. Storicamente si sono succeduti diversi approcci alla rappresentazione della conoscenza:

- **Sistemi basati su regole**: un esperto umano formalizza a mano regole logiche deduttive; il sistema non apprende.
- **Machine Learning classico**: l'esperto seleziona e calcola manualmente feature rilevanti dai dati grezzi (*feature engineering*); l'algoritmo apprende unicamente la funzione di mappatura dalle feature all'output.
- **Representation Learning**: il sistema apprende in autonomia anche le trasformazioni intermedie dai dati grezzi alle feature (es. *autoencoder*).

- **Deep Learning:** si elimina la necessità dell'esperto umano nella fase di estrazione delle feature. Si forniscono al modello i dati grezzi e si addestrano reti neurali profonde a strati nascosti multipli (*hidden layers*): ogni livello calcola rappresentazioni interne via via più astratte combinando le feature dello strato precedente.

1.3 Alberi di Decisione ed Espressività

Formalizziamo il problema dell'approssimazione supervisionata. Dato uno spazio di input X , uno spazio di etichette Y e un training set di N campioni $\mathcal{D} = \{\langle \mathbf{x}^{(i)}, y^{(i)} \rangle\}_{i=1}^N$, si intende stimare la funzione ignota $f : X \rightarrow Y$. Ogni tecnica richiede l'adozione di uno **spazio delle ipotesi** $H = \{h \mid h : X \rightarrow Y\}$, all'interno del quale ricercare la funzione h che meglio approssima f sui dati noti di addestramento.

Un **albero di decisione** è un modello gerarchico per la classificazione:

- Ciascun **nodo interno** esegue un test su un determinato attributo X_j .
- Ciascun **ramo** uscente corrisponde a uno dei possibili valori discreti assunti dall'attributo.
- Ciascuna **foglia** terminale restituisce la classe predetta y (oppure una probabilità condizionata $P(Y \mid X)$).

Training Set di Riferimento: Problema <i>Play Tennis</i>				
Outlook	Temperature	Humidity	Wind	Play Tennis?
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

Nel dominio delle variabili booleane, gli alberi di decisione possiedono un'espressività completa: possono rappresentare qualsiasi combinazione logica in **forma normale disgiuntiva (DNF)**, in cui ogni cammino dalla radice a una foglia con etichetta positiva corrisponde a una congiunzione di test ($\wedge$) e l'albero intero costituisce la disgiunzione ($\vee$) dei percorsi favorevoli. Poiché la rappresentazione di una funzione logica non è unica, in accordo con il principio del **Rasoio di Occam** si preferisce l'albero più compatto e di profondità minore, riducendo il rischio di modellare rumore statistico.

1.4 Costruzione Top-Down, Entropia e Information Gain

La determinazione dell'albero ottimo globale è un problema *NP*-completo. Si adotta quindi un approccio euristico induttivo di tipo **greedy top-down** (algoritmo ID3):

1. Si individua l'attributo migliore X_j per il nodo corrente.
2. Si genera un nodo figlio per ciascun valore discreto ammissibile di X_j .
3. Se tutti i campioni associati a un figlio appartengono alla medesima classe, il nodo diventa una foglia etichettata con tale classe; altrimenti si ripete ricorsivamente la procedura sui dati del sotto-nodo.

La scelta dell'attributo migliore viene guidata dai concetti della **Teoria dell'Informazione di Shannon**:

- **Quantità di informazione (sorpresa)**: un evento con probabilità p trasmette un'informazione $I(p) = -\log_2(p)$. Per due eventi indipendenti le probabilità si moltiplicano, mentre l'informazione acquisita è additiva: $I(p_1 p_2) = I(p_1) + I(p_2)$.
- **Entropia** $H(X)$: definita come il valore atteso della sorpresa, quantifica l'impurità o l'incertezza media di una distribuzione:

$$H(X) = - \sum_{i=1}^n P(X = i) \log_2 P(X = i)$$

Assume valore 0 se l'esito è certo e tocca il massimo $\log_2(n)$ quando tutti gli n eventi sono equiprobabili.

- **Teoria dei codici**: l'entropia definisce il numero medio minimo di bit necessari per codificare e trasmettere senza perdite i campioni generati dalla sorgente.

Guadagno di Informazione (*Information Gain*)

Dati la variabile target Y e un attributo predittivo candidato X , l'incertezza residua dopo aver osservato X è data dall'**entropia condizionata**:

$$H(Y | X) = \sum_{v \in \text{Valori}(X)} P(X = v) H(Y | X = v)$$

L'**Information Gain** $I(Y, X)$ quantifica la riduzione netta di entropia ottenuta partizionando i dati tramite l'attributo X :

$$I(Y, X) = H(Y) - H(Y | X)$$

L'euristica seleziona a ogni passo l'attributo che massimizza il guadagno di informazione.

Esempio numerico di selezione tra due attributi A e B :

Si consideri un nodo con 64 esempi, di cui 29 positivi e 35 negativi, denotato come $[29+, 35-]$. L'entropia iniziale del nodo è:

$$H(Y) = -\frac{29}{64} \log_2 \left(\frac{29}{64} \right) - \frac{35}{64} \log_2 \left(\frac{35}{64} \right) \approx 0.994 \text{ bit}$$

- **Attributo A:** suddivide il nodo nei rami T (26 campioni: $[21+, 5-]$) ed F (38 campioni: $[8+, 30-]$).

$$H(Y | A = T) = -\frac{21}{26} \log_2 \left(\frac{21}{26} \right) - \frac{5}{26} \log_2 \left(\frac{5}{26} \right) \approx 0.706 \text{ bit}$$

$$H(Y | A = F) = -\frac{8}{38} \log_2 \left(\frac{8}{38} \right) - \frac{30}{38} \log_2 \left(\frac{30}{38} \right) \approx 0.742 \text{ bit}$$

$$H(Y | A) = \frac{26}{64}(0.706) + \frac{38}{64}(0.742) \approx 0.726 \implies I(Y, A) = 0.994 - 0.726 = \mathbf{0.268} \text{ bit}$$

- **Attributo B:** suddivide il nodo nei rami T (51 campioni: $[18+, 33-]$) ed F (13 campioni: $[11+, 2-]$).

$$H(Y | B = T) \approx 0.936 \text{ bit}, \quad H(Y | B = F) \approx 0.619 \text{ bit}$$

$$H(Y | B) = \frac{51}{64}(0.936) + \frac{13}{64}(0.619) \approx 0.872 \implies I(Y, B) = 0.994 - 0.872 = \mathbf{0.122} \text{ bit}$$

Essendo $I(Y, A) > I(Y, B)$, l'algoritmo seleziona l'attributo A come criterio di diramazione.

1.5 Attributi Continui e Gestione delle Soglie

Quando gli attributi assumono valori continui su scala reale ($X_j \in \mathbb{R}$), non è praticabile generare un ramo per ogni valore osservato. Si converte pertanto il test continuo in una scelta dicotomica tramite una **soglia di decisione** (*threshold*) Θ , definendo una condizione binaria del tipo:

$$A < \Theta \quad \vee \quad A \geq \Theta$$

Il valore ottimale di Θ viene individuato confrontando l'*Information Gain* prodotto da differenti soglie candidate:

- **Campionamento a intervalli discreti:** si valuta una griglia prefissata di valori equispaziati lungo il dominio dell'attributo.
- **Valori medi tra campioni adiacenti:** si ordina il training set rispetto all'attributo considerato e si scelgono come soglie candidate le medie aritmetiche tra coppie di valori consecutivi associati a classi differenti:

$$\Theta = \frac{x^{(k)} + x^{(k+1)}}{2}$$

```

1 from sklearn import tree
2
3 # Esempio con feature binarie/continue
4 X = [[0,0,0,0], [1,0,0,0], [0,0,0,1], [0,0,1,0], [0,0,1,1],
5      [0,1,0,0], [0,1,0,1], [1,1,0,1], [0,1,1,0], [0,1,1,1]]
6 Y = [0, 0, 1, 1, 0, 0, 1, 1, 1, 0] # y = 1 se X[2] != X[3], 0 altrimenti
7
8 clf = tree.DecisionTreeClassifier(criterion='entropy', random_state=0)
9 clf = clf.fit(X, Y)
10
11 print("Predizione:", clf.predict([[1, 1, 1, 1]]))
12 print("Feature importances:", clf.feature_importances_)

```

In presenza di relazioni complesse tra attributi (come la funzione XOR tra due feature), il guadagno d'informazione univariato calcolato alla radice può risultare nullo o fuorviante per i singoli attributi presi isolatamente. Nonostante ciò, la metrica di **Feature Importance** calcolata *ex post* riflette fedelmente il contributo complessivo di ciascun attributo, ponderando la riduzione di impurità prodotta in ciascun nodo per il volume di campioni che lo attraversano.

1.6 Overfitting, Compromesso Bias-Varianza e Tecniche di Potatura

Si consideri l'errore commesso da un'ipotesi $h \in H$:

- $error_{train}(h)$: errore empirico calcolato sul training set di addestramento.
- $error_{\mathcal{D}}(h)$: errore atteso calcolato sull'intera distribuzione teorica $\mathcal{D}$.

Un'ipotesi h soffre di **overfitting** (sovradattamento) se esiste un'altra ipotesi $h' \in H$ tale per cui:

$$error_{train}(h) < error_{train}(h') \quad \text{ma} \quad error_{\mathcal{D}}(h) > error_{\mathcal{D}}(h')$$

Il Compromesso tra Bias e Varianza (*Bias-Variance Trade-off*)

La capacità di generalizzazione di un modello dipende criticamente dalla sua complessità strutturale:

- **Modelli poco complessi** (bassa flessibilità) esibiscono **alto bias** e **bassa varianza**: le assunzioni a priori sono troppo rigide, portando a prestazioni insoddisfacenti sia sui dati noti che sui dati futuri (**underfitting**).
- **Modelli iper-complessi** esibiscono **basso bias** ed **elevata varianza**: il modello modella fedelmente il rumore statistico del training set, annullando l'errore di addestramento ma fallendo nel generalizzare (**overfitting**).

Poiché la distribuzione reale $\mathcal{D}$ non è direttamente campionabile, si partiziona il dataset a disposizione in due insiemi disgiunti: un **training set**, usato per calibrare i parametri dell'ipotesi h , e un **validation set**, impiegato come stima oggettiva della capacità predittiva su dati non visti.

Negli alberi di decisione, il controllo dell'overfitting si realizza attraverso due metodologie complementari:

- **Early Stopping (Arresto Anticipato)**: si arresta la ramificazione dell'albero quando il miglioramento di purezza scende al di sotto di una soglia prestabilita o quando il nodo contiene un numero di campioni inferiore a un limite minimo.
- **Post-Pruning (Potatura Retrograda)**: si sviluppa l'albero fino alla massima profondità possibile e si procede successivamente a potarlo a ritroso.

Algoritmo di Reduced-Error Post-Pruning

1. Si genera l'albero di decisione completo che classifica perfettamente il training set.
2. Si itera la seguente procedura finché la rimozione di nodi apporta benefici:

- (a) Per ogni sottoalbero interno non fogliare, si misura l'impatto della sua potatura (rimpiazzo con una foglia avente la classe maggioritaria) sull'accuratezza valutata sul *validation set*.
- (b) Si elimina con approccio *greedy* il sottoalbero la cui rimozione massimizza il guadagno di accuratezza sul *validation set*.

1.7 Criteri Alternativi di Impurità ed Ensemble Learning

In alternativa all'entropia shannoniana, si ricorre ampiamente all'**Impurità di Gini** (I_G). Essa esprime la probabilità che un campione selezionato a caso riceva un'etichetta errata se etichettato casualmente secondo la distribuzione marginale delle classi nel nodo. Dato un nodo con m categorie in cui f_i indica la frazione di elementi di classe i , la probabilità di errore associata è $(1 - f_i)$. La media pesata su tutte le etichette fornisce:

$$I_G(f) = \sum_{i=1}^m f_i(1 - f_i) = \sum_{i=1}^m f_i - \sum_{i=1}^m f_i^2 = 1 - \sum_{i=1}^m f_i^2$$

Valutazione comparativa tra attributi A e B tramite Impurità di Gini:

Riprendendo il nodo con 64 campioni ([29+, 35-]):

- **Attributo A:** partiziona nei rami T (26 campioni: [21+, 5-]) ed F (38 campioni: [8+, 30-]).

$$I_G(A = T) = 1 - \left(\frac{21}{26}\right)^2 - \left(\frac{5}{26}\right)^2 \approx 0.310$$

$$I_G(A = F) = 1 - \left(\frac{8}{38}\right)^2 - \left(\frac{30}{38}\right)^2 \approx 0.332$$

$$I_G(A) = \frac{26}{64}(0.310) + \frac{38}{64}(0.332) = \mathbf{0.323}$$

- **Attributo B:** partiziona nei rami T (51 campioni: [18+, 33-]) ed F (13 campioni: [11+, 2-]).

$$I_G(B = T) = 1 - \left(\frac{18}{51}\right)^2 - \left(\frac{33}{51}\right)^2 \approx 0.456$$

$$I_G(B = F) = 1 - \left(\frac{11}{13}\right)^2 - \left(\frac{2}{13}\right)^2 \approx 0.260$$

$$I_G(B) = \frac{51}{64}(0.456) + \frac{13}{64}(0.260) = \mathbf{0.416}$$

Poiché $I_G(A) < I_G(B)$, lo split indotto dall'attributo A produce un'impurità residua inferiore, venendo prescelto.

Proprietà degli Alberi di Decisione e Random Forests

Gli alberi di decisione presentano vantaggi operativi rilevanti:

- **Interpretabilità diretta:** le regole di decisione sono ispezionabili e traducibili in

formule logiche.

- **Pre-elaborazione minima:** gestiscono nativamente dati numerici e categorici senza richiedere normalizzazione o standardizzazione.
- **Basso costo di inferenza:** la predizione richiede tempo logaritmico rispetto al numero di nodi.

Di contro, manifestano forte tendenza all'**overfitting**, alta varianza e instabilità strutturale rispetto a fluttuazioni del dataset, oltre a una vulnerabilità allo sbilanciamento delle classi. Per ovviare a tali limiti si adotta il paradigma delle **Random Forest**, metodi ensemble basati sul principio per cui una pluralità di modelli debolmente correlati operanti come comitato supera la performance del singolo classificatore costituente. La decorrelazione è garantita da:

- **Bagging (*Bootstrap Aggregating*):** addestramento di ogni singolo albero su un sottoinsieme di campioni estratto casualmente con reinserimento (*bootstrap*) dal training set.
- **Feature Randomness:** a ogni nodo, la ricerca del miglior criterio di divisione è vincolata a un sottoinsieme casuale ristretto di feature.

Sintesi dei Concetti Cardine dell'Apprendimento Induttivo

L'apprendimento supervisionato ricerca la funzione ottima all'interno dello spazio delle ipotesi H . Tra le ipotesi compatibili con i dati di addestramento si predilige la più parsimoniosa (Rasoio di Occam). Infine, il celebre **Teorema No Free Lunch (NFL)** stabilisce formalmente che nessun algoritmo di apprendimento può essere universalmente superiore a tutti gli altri su qualunque classe di problemi: qualsiasi capacità predittiva su dati non osservati necessita imprescindibilmente di un **bias induttivo** (insieme di assunzioni a priori sulla struttura dei dati).

1.8 Il Paradigma Probabilistico e Fondamenti Assiomatici

Nel paradigma deterministico l'obiettivo primario è stimare una funzione esplicita $f : X \rightarrow Y$. L'approccio probabilistico riformula il compito valutando la distribuzione condizionata:

$$P(Y | X)$$

stimando la verosimiglianza di ciascuna classe Y una volta acquisita l'evidenza delle feature X . Definiamo formalmente gli elementi costitutivi della teoria della probabilità:

- **Spazio Campionario (Ω):** l'insieme di tutti i possibili esiti elementari associati a un esperimento aleatorio.
- **Variabile Aleatoria (X):** funzione misurabile definita sullo spazio campionario $\Omega \rightarrow \mathbb{R}$. Se l'insieme immagine è discreto si ha una variabile aleatoria discreta ($X : \Omega \rightarrow \{v_1, \dots, v_k\}$), se è continuo si ha una variabile continua.
- **Evento (A):** sottoinsieme misurabile dello spazio campionario ($A \subseteq \Omega$).

Definizione rigorosa dello Spazio Campionario: l'intuizione probabilistica classica postula l'equiprobabilità degli eventi elementari. Nel lancio simultaneo di due dadi a sei facce, modellare gli esiti come la somma dei punti $\{2, 3, \dots, 12\}$ è fallace poiché le somme non hanno la medesima probabilità; lo spazio campionario uniforme è costituito dalle 36 coppie ordinate di esiti $\Omega = \{1, \dots, 6\} \times \{1, \dots, 6\}$, su cui la somma costituisce una specifica variabile aleatoria derivata.

Assiomi della Teoria della Probabilità (Kolmogorov)

Sia Ω lo spazio campionario e P una funzione a valori reali definita sulla famiglia degli eventi:

1. $0 \leq P(A) \leq 1 \quad \forall A \subseteq \Omega$
2. $P(\Omega) = P(\text{True}) = 1, \quad P(\emptyset) = P(\text{False}) = 0$
3. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Teorema dell'Evento Complementare

$$P(\neg A) = 1 - P(A)$$

Dimostrazione. Applicando l'assioma di unione a $B = \neg A$:

$$P(A \cup \neg A) = P(A) + P(\neg A) - P(A \cap \neg A)$$

Poiché $A \cup \neg A = \Omega \implies P(\Omega) = 1$ e $A \cap \neg A = \emptyset \implies P(\emptyset) = 0$:

$$1 = P(A) + P(\neg A) - 0 \implies P(\neg A) = 1 - P(A) \quad \square$$

Teorema della Probabilità Totale (Formulazione Binaria)

$$P(A) = P(A \cap B) + P(A \cap \neg B)$$

Dimostrazione. Poiché $A = A \cap (B \cup \neg B) = (A \cap B) \cup (A \cap \neg B)$, ed essendo $(A \cap B)$ e $(A \cap \neg B)$ eventi disgiunti:

$$P(A) = P(A \cap B) + P(A \cap \neg B) - P((A \cap B) \cap (A \cap \neg B)) = P(A \cap B) + P(A \cap \neg B) - 0 \quad \square$$

Per una variabile aleatoria discreta A che assume uno tra k valori mutualmente esclusivi ed esaustivi $\{\nu_1, \nu_2, \dots, \nu_k\}$:

$$P(A = \nu_i \wedge A = \nu_j) = 0 \quad \forall i \neq j$$

$$\sum_{i=1}^k P(A = \nu_i) = P\left(\bigvee_{i=1}^k (A = \nu_i)\right) = 1$$

1.9 Probabilità Condizionata, Regola della Catena e Indipendenza Stocastica

Dati due eventi A e B con $P(B) > 0$, la **probabilità condizionata** di A dato il verificarsi di B è definita analiticamente come:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

Geometricamente, corrisponde alla normalizzazione dell'area di intersezione $A \cap B$ rispetto all'area del nuovo spazio campionario ridotto all'evento condizionante B .

Riordinando i termini si ricava la **regola della catena** (*chain rule*):

$$P(A \cap B) = P(B) P(A | B) = P(A) P(B | A)$$

Due eventi A e B sono **stocasticamente indipendenti** se la conoscenza dell'esito di B non altera la probabilità di A :

$$P(A | B) = P(A)$$

Ne consegue immediatamente l'espressione fattorizzata della probabilità congiunta:

$$P(A \cap B) = P(A) P(B)$$

da cui deriva reciprocamente che $P(B | A) = P(B)$.